2026년도 AI 기반 심장질환 위험 예측 모델 개발

AI개발 수행내역서

과제명	AI 기반 심장질환 위험 예측 모델 개발
담당자	김민수

2026년 04월 02일

AI개발 수행내용

1. 목표 : AI 기반 심장질환 위험 예측 모델 개발

2. 개요 및 현황

2.1 추진배경 및 목적

○ 심장·혈관 질환은 전 세계적으로 사망 원인 상위에 해당하는 대표적인 만성질환이며, 조기에 위험을 식별할수록 치료·관리 효과가 커집니다.

○ 의료 현장에서는 환자의 연령, 혈압, 콜레스테롤, 운동부하 검사 결과 등 정형 데이터를 활용해 위험도를 평가하는 연구가 꾸준히 진행되고 있습니다.

○ 본 과제는 UCI 심장질환 공개 데이터를 활용하여, 환자 특성 정보로 심장질환 유무(또는 위험 유무)를 예측하는 분류 모델을 구축하고 성능을 정량적으로 평가하는 것을 목적으로 합니다.

○ 이를 통해 데이터 기반으로 주요 위험 요인을 파악하고, 시각화로 결과를 설명 가능한 형태로 제시합니다.

2.2 과제 범위

과제구분		내용
AI	AI기반 심장질환 위험 예측 모델 개발	원시 데이터 수집 및 데이터셋 구축
		데이터 전처리, 표준화, 상관관계 분석 (EDA도구 활용)
		예측모델 선정 및 학습
		정확도, 혼동행렬 등 평가지표를 활용한 모델 성능 평가
		웹 API 및 프로토타입 구축
		예측모델 웹기반 시스템 구축
		테스트

2.3 과제 추진 방법

1) 추진 방법

○ 데이터 적합성 및 재현성

■ 심장 질환 관련 임상·검사 지표가 포함된 공개 정형 데이터셋을 분석 대상으로 선정함.

■ 데이터의 출처와 변수 정의가 명확하여 탐색적 데이터 분석, 전처리, 모델 학습 및 성능 평가 절차를 동일 조건에서 재현 가능함.

○ 예측모델 실현 가능성

■ 분석 단위가 환자별 레코드로 구성되어 있으며 연속형·범주형 변수가 함께 포함되어, 분류 모델 개발 및 변수 중요도 분석에 적합함.

■ 타겟 변수를 이진화하여 분류 문제로 정의 가능하며, 혼동행렬과 정확도 같은 지표로 결과를 확인 가능함.

○ 활용 목적 및 기대 효과

■ 심장질환 가능성이 높은 사람을 미리 구분해, 조기 검사나 건강관리 방향을 잡는 데 도움을 줄 수 있음.

■ 데이터 기반으로 결과를 보여주기 때문에, 주관적인 판단보다 근거 있는 설명이 가능함.

2) AI 예측 분석모델 적용 대상

구분	수집 데이터	예측모델인자	AI예측 분석 대상
심장질환 위험 예측 및 고위험군 분류	- UCI Heart Disease 공개 데이터셋 - 환자별 임상·검사 정보 포함 데이터	- 인구통계 : 나이, 성별 - 증상/진단 관련 : 흉통 유형, 운동 유발 협심증, 운동 유발성 협심증, 운동 후 심전도 저하 수치, 심장 혈류 상태 - 검사 지표 : 안정시 혈압, 콜레스테롤, 공복혈당, 안정 시 심전도 결과, 최대 심박 수, 주요 혈관 수 - 제외 변수 :식별자, 출처 구분용 컬럼(모델 입력에서 제외)	- 심장질환 유무 예측 - 고위험군 조기 판별 및 위험요인 분석

3) AI 분석모델 구축 프로세스

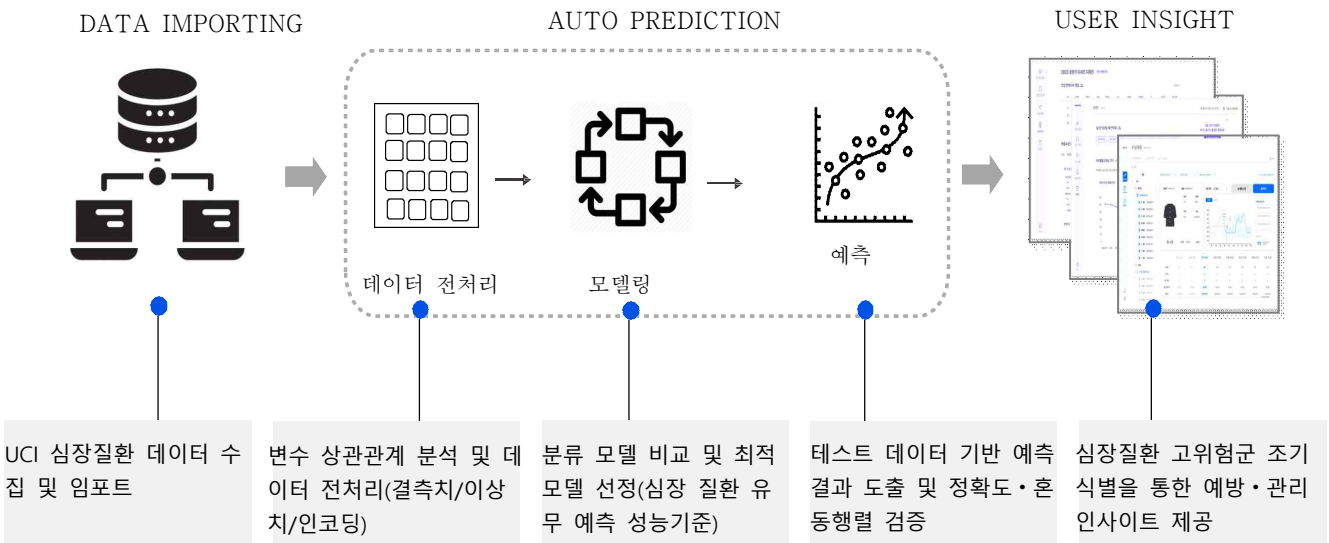

연구개발 주요 결과물

1. 데이터 수집

- UCI Heart Disease Data, 심장 질환 관련 데이터(Excel)
- https://www.kaggle.com/datasets/redwankarimsony/heart-disease-data

나이	성별	표준진료지침	안정 시 혈	콜레스테	공복 혈당	안정 시 심전도	최대 심박	운동 유발성 협	운동 후 심	운동 후 심전도	주요 혈	심장 혈류 상태	심장병
63	남	전형적 협심증(흉통)	145	233	TRUE	좌심실 비대	150	FALSE	2.3	downsloping	0	혈관 영구 손상	0
67	남	무증상	160	286	FALSE	좌심실 비대	108	TRUE	1.5	flat	3	정상	2
67	남	무증상	120	229	FALSE	좌심실 비대	129	TRUE	2.6	flat	2	일시적 혈관 ㅁ	1
37	남	비협심증성(심장 혈관C	130	250	FALSE	정상	187	FALSE	3.5	downsloping	0	정상	0
41	여	비전형적 흉통	130	204	FALSE	좌심실 비대	172	FALSE	1.4	upsloping	0	정상	0
56	남	비전형적 흉통	120	236	FALSE	정상	178	FALSE	0.8	upsloping	0	정상	0
62	여	무증상	140	268	FALSE	좌심실 비대	160	FALSE	3.6	downsloping	2	정상	3
57	여	무증상	120	354	FALSE	정상	163	TRUE	0.6	upsloping	0	정상	0
63	남	무증상	130	254	FALSE	좌심실 비대	147	FALSE	1.4	flat	1	일시적 혈관 ㅁ	2
53	남	무증상	140	203	TRUE	좌심실 비대	155	TRUE	3.1	downsloping	0	일시적 혈관 ㅁ	1
57	남	무증상	140	192	FALSE	정상	148	FALSE	0.4	flat	0	혈관 영구 손상	0
56	여	비전형적 흉통	140	294	FALSE	좌심실 비대	153	FALSE	1.3	flat	0	정상	0
56	남	비협심증성(심장 혈관C	130	256	TRUE	좌심실 비대	142	TRUE	0.6	flat	1	혈관 영구 손상	2
44	남	비전형적 흉통	120	263	FALSE	정상	173	FALSE	0	upsloping	0	일시적 혈관 ㅁ	0
52	남	비협심증성(심장 혈관C	172	199	TRUE	정상	162	FALSE	0.5	upsloping	0	일시적 혈관 ㅁ	0
57	남	비협심증성(심장 혈관C	150	168	FALSE	정상	174	FALSE	1.6	upsloping	0	정상	0
48	남	비전형적 흉통	110	229	FALSE	정상	168	FALSE	1	downsloping	0	일시적 혈관 ㅁ	1
54	남	무증상	140	239	FALSE	정상	160	FALSE	1.2	upsloping	0	정상	0
48	여	비협심증성(심장 혈관C	130	275	FALSE	정상	139	FALSE	0.2	upsloping	0	정상	0
49	남	비전형적 흉통	130	266	FALSE	정상	171	FALSE	0.6	upsloping	0	정상	0
64	남	전형적 협심증(흉통)	110	211	FALSE	좌심실 비대	144	TRUE	1.8	flat	0	정상	0
58	여	전형적 협심증(흉통)	150	283	TRUE	좌심실 비대	162	FALSE	1	upsloping	0	정상	0
58	남	비전형적 흉통	120	284	FALSE	좌심실 비대	160	FALSE	1.8	flat	0	정상	1
58	남	비협심증성(심장 혈관C	132	224	FALSE	좌심실 비대	173	FALSE	3.2	upsloping	2	일시적 혈관 ㅁ	3
60	남	무증상	130	206	FALSE	좌심실 비대	132	TRUE	2.4	flat	2	일시적 혈관 ㅁ	4
50	여	비협심증성(심장 혈관C	120	219	FALSE	정상	158	FALSE	1.6	flat	0	정상	0
58	여	비협심증성(심장 혈관C	120	340	FALSE	정상	172	FALSE	0	upsloping	0	정상	0
66	여	전형적 협심증(흉통)	150	226	FALSE	정상	114	FALSE	2.6	downsloping	0	정상	0
43	남	무증상	150	247	FALSE	정상	171	FALSE	1.5	upsloping	0	정상	0
40	남	무증상	110	167	FALSE	좌심실 비대	114	TRUE	2	flat	0	일시적 혈관 ㅁ	3

- 표준진료지침(흉통 유형) : 무증상 심근허혈, 전형적 협심증(흉통), 비협심증성(심장외 흉통), 비전형적 흉통(원인 불분명)
- 공복 혈당 (True/False) : 기준점 120 mg/dl를 초과하면 True 이하면 False
- 안정 시 심전도 결과 : 좌심실 비대(혈액 펌프 과부하), ST-T파 이상(심장 회복 불안정)
- 운동 후 심전도 저하 수치 : 0과 가까울수록 정상 0과 멀어질수록 심장 혈관이 서서히 막힘으로 혈류 부족
- 운동 후 심전도 회복 패턴 : 상향이면 정상, 수평이면 위험군, 하향이면, 고위험군
- 주요 혈관, 심장 혈류 상태 : 결측치가 50% 이상으로 데이터로써 부적합하여 삭제

2. 데이터 분석

○ 결측치 및 중복값 통계

- 전체 데이터 : 920건(100%), 결측 데이터 : 1759건(13,7%), 중복 데이터 : 2건(0.2%)

Overview | Alerts 12 | Reproduction

Dataset statistics

Number of variables	14
Number of observations	920
Missing cells	1759
Missing cells (%)	13.7%
Duplicate rows	2
Duplicate rows (%)	0.2%
Total size in memory	508.2 KiB
Average record size in memory	565.7 B

Variable types

Numeric	5
Categorical	7
Boolean	2

○ 주요 변수별 데이터 분포(Histogram)

■ 나이, 안정 시 혈압, 최대 심박 수

- 데이터가 특정 수치에 편중되지 않고 고르게 분포되어 있어, 모델 학습 시 편향 발생 가능성 낮음

■ 콜레스테롤, 운동 후 심전도 저하

- 콜레스테롤의 경우 400 이상의 극단적 수치가 존재하고, 운동 후 심전도 저하는 대다수가 0에 근접해 있음. 이는 특정 고위험군 데이터가 소수 존재함을 의미함.

■ 심장병 진단 결과

- 클래스 불균형이 확인되어 일반적인 정확도 지표만으로 모델 성능을 신뢰하기 어려움.

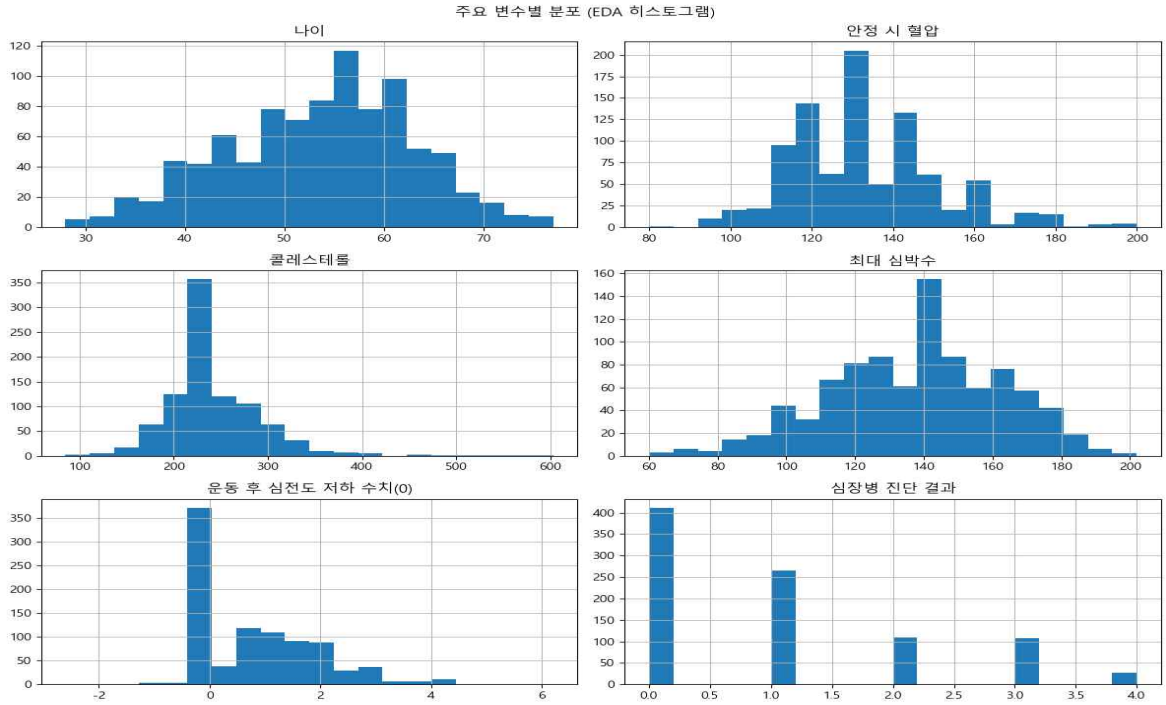

○ 변수 간 상관관계 분석 (산점도)

■ 가장 높은 상관성을 보인 주요 변수들을 산점도로 정밀 분석한 결과, 특정 수치 이상에서 위험군이 밀집되는 양상을 확인.

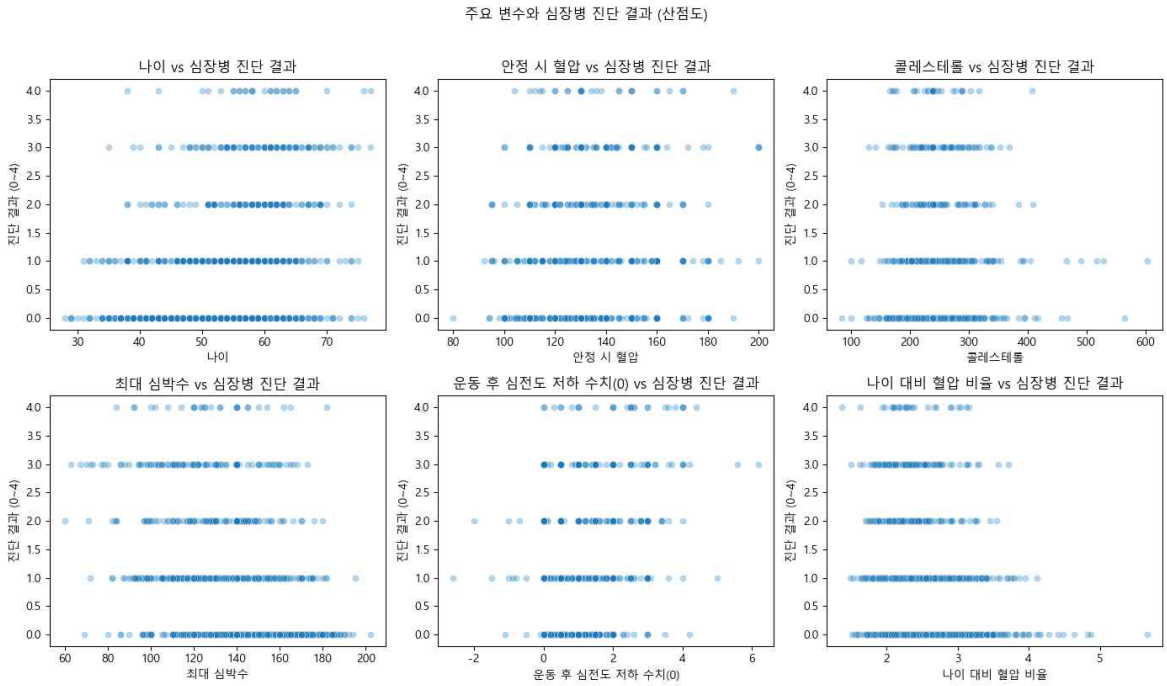

○ 심장 질환 데이터 상관관계(히트맵)

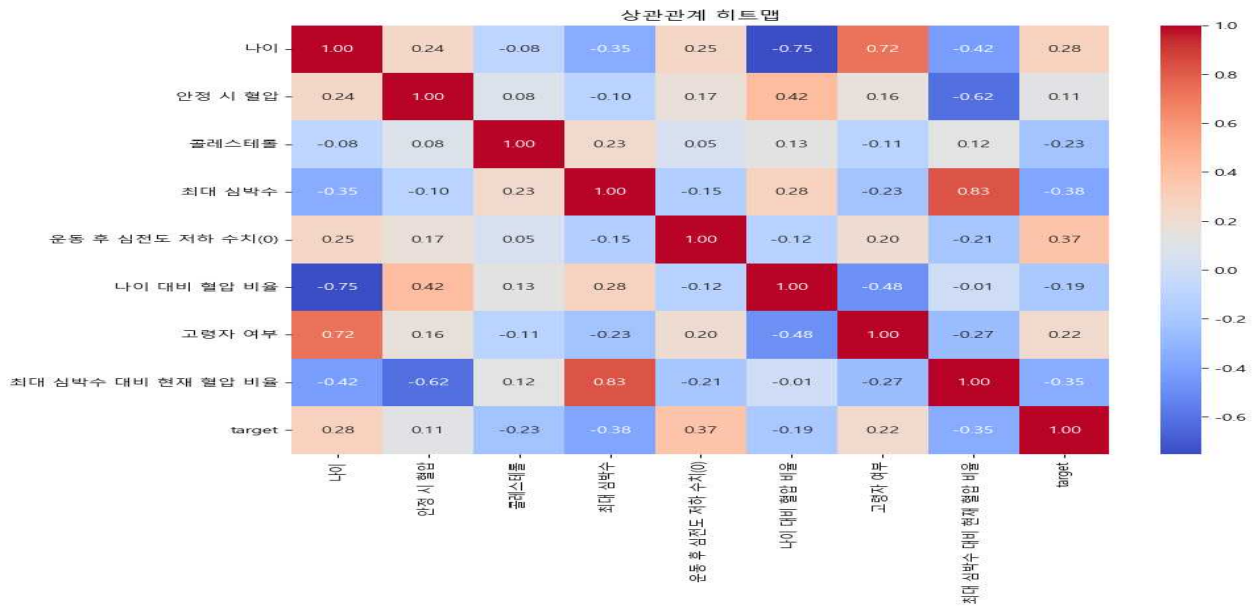

○ 상관관계 분석 결과 주요 발견사항

■ 나이 대비 혈압 비율과 target 간 음의 상관관계가 가장 높게 나타나 해당 파생 변수가 질환 예측의 핵심 독립 변수임을 확인

■ 최대 심박수와 나이는 음의 상관(-0.35)을 보이며, 이는 고령일수록 최대 심박수가 낮아지는 임상적 의학 지식과 데이터가 일치함을 증명

○ 데이터 전처리

■ 결측치 : 결측치가 50% 넘어가는 컬럼은 분석 대상에서 제외

■ 이상치 보정 : 논리적 오류 수정, 생물학적으로 0이 불가능한 변수 결측치로 간주하여 처리

■ 데이터 변환 : 다중 분류 데이터를 이진 분류로 변환, 예측 정확도 최적화

First rows Last rows

	나이	성별	표준진료지침	안정 시 혈압	콜레스테롤	공복 혈당 여부	안정 시 심전도 결과	최대 심박수	운동 유발성 협심증
0	63	남	전형적 협심증(흉통)	145.0	233.0	True	좌심실 비대	150.0	False
1	67	남	무증상	160.0	286.0	False	좌심실 비대	108.0	True
2	67	남	무증상	120.0	229.0	False	좌심실 비대	129.0	True
3	37	남	비협심증성(심장 혈관이외)	130.0	250.0	False	정상	187.0	False
4	41	여	비전형적 흉통	130.0	204.0	False	좌심실 비대	172.0	False
5	56	남	비전형적 흉통	120.0	236.0	False	정상	178.0	False
6	62	여	무증상	140.0	268.0	False	좌심실 비대	160.0	False
7	57	여	무증상	120.0	354.0	False	정상	163.0	True
8	63	남	무증상	130.0	254.0	False	좌심실 비대	147.0	False
9	53	남	무증상	140.0	203.0	True	좌심실 비대	155.0	True

3. 데이터 학습 및 모델정의

3.1 모델 성능 비교

분류	로지스틱 회귀	의사결정 나무	랜덤 포레스트	XGBoost
정확도	0.788	0.766	0.772	0.783
재현율	0.833	0.784	0.824	0.823
F-1 점수	0.813	0.788	0.8	0.807

○ **로지스틱 회귀 모델 선정**

- 4개 모델 비교 결과 로지스틱 회귀가 전 지표에서 가장 높은 성능을 보임. 특히 심장질환 특성상 실제 환자를 놓치는 것이 위험하므로 재현율을 핵심 지표로 설정하였으며, 추가로 계수 해석이 가능해 의료 분야에서 설명 가능성이 높다는 장점도 고려

○ 모델 비교 시각화

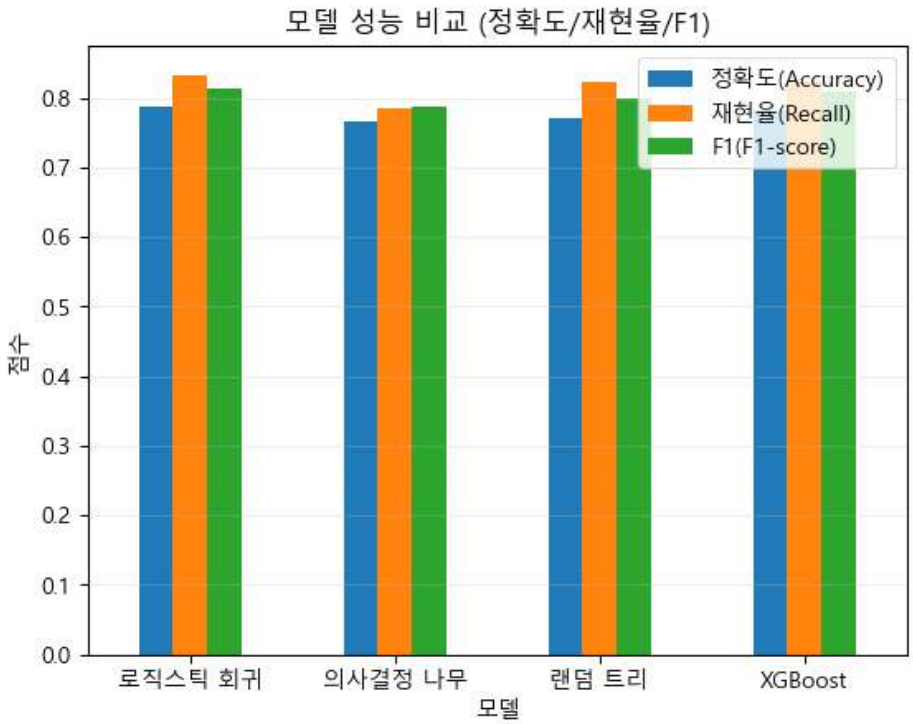

○ 최적 모델 성능 :

- 정확도 : 0.7554
- 재현율 : 0.8824
- F1_score : 0.8

3.2 모델 학습 결과 및 다각적 성능 검증

○ 모델 비교 시각화

- 현상 파악 : 파라미터 C값이 0.001(강한 규제)지점에서 교차검증 재현율 점수가 약 0.88로 가장 높게 나타남 이후 C값이 커짐(규제 완화)에 따라 점수가 하락 하여 C = 1 부근에 약 0.81 수준으로 수렴.
- 수렴 확인 : 값이 1을 초과하여 10, 100으로 증가해도 재현율 점수의 유의미한 변화는 없으나, 값이 작을 때(강한 규제)보다 오차 막대의 변동 폭이 커지는 것을 확인할 수 있음.
- 최종 결론 : Recall 점수 자체는 C = 0.001에서 가장 높으나, 모델의 일반화 성능과 안정적인 예측력을 고려하여 성능이 일정하게 유지되기 시작하는 C = 1을 최종 하이퍼파라미터로 확정함

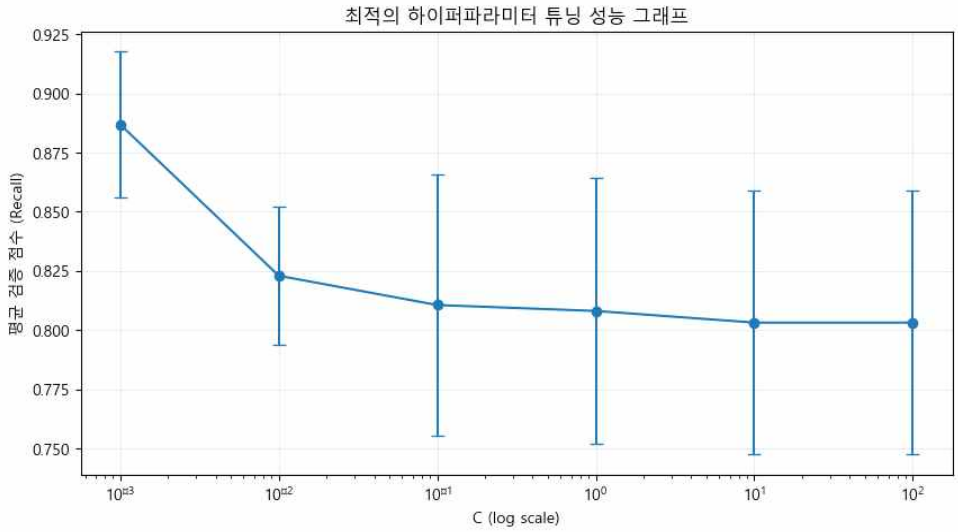

○ 모델 ROC 커브

- ROC-AUC를 통한 분류 성능 입증.

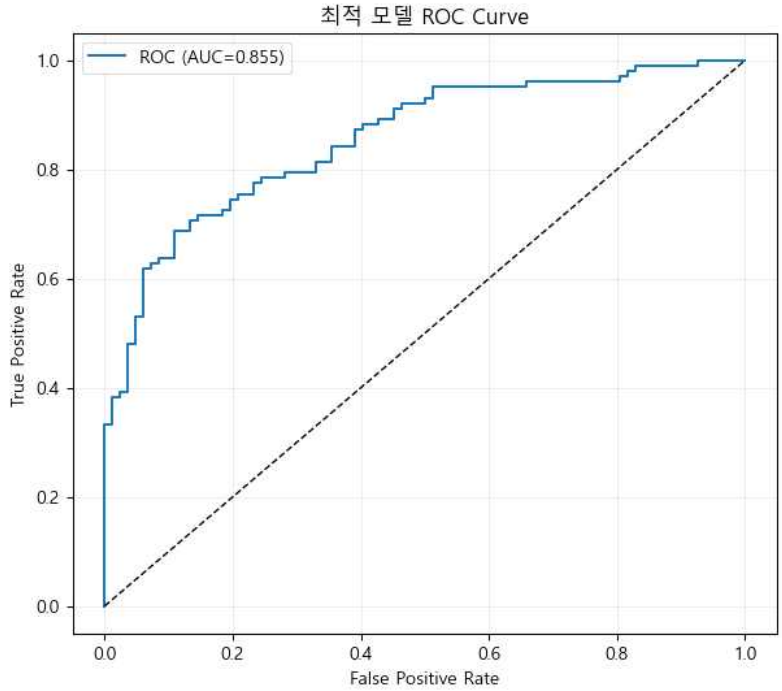

○ 알고리즘 기반 변수별 상대적 중요도 식별

- 모델이 판단한 심장질환 예측의 주요 기여 변수 순위 도출

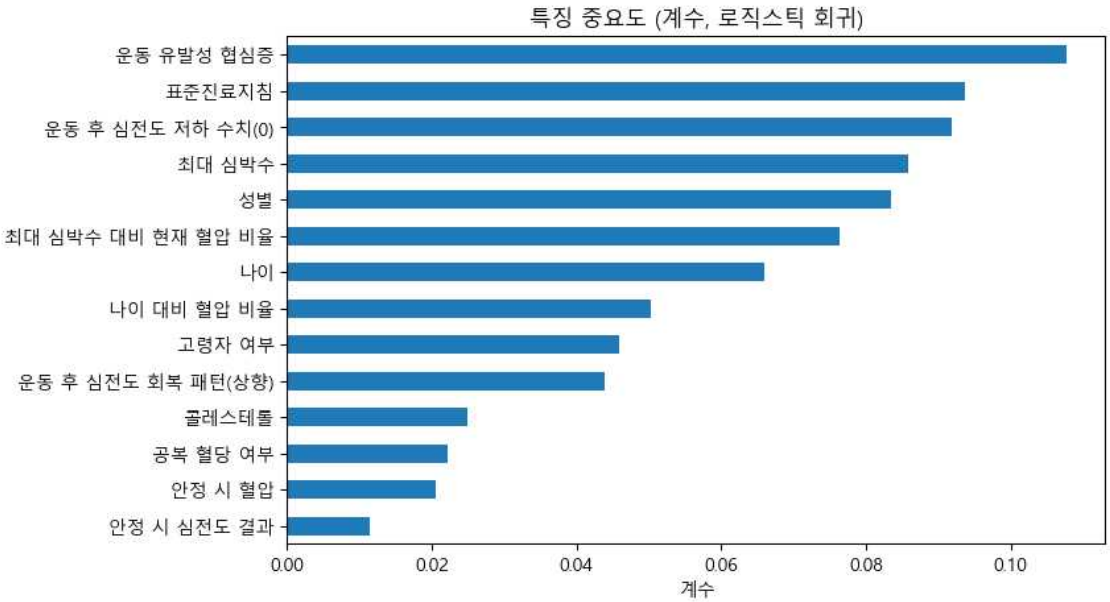

○ 순열 중요도 기반 핵심 위험 인자 재검증

- 데이터 무작위 셔플링을 통해 모델 성능에 실질적 영향을 미치는 독립변수 순위 도출

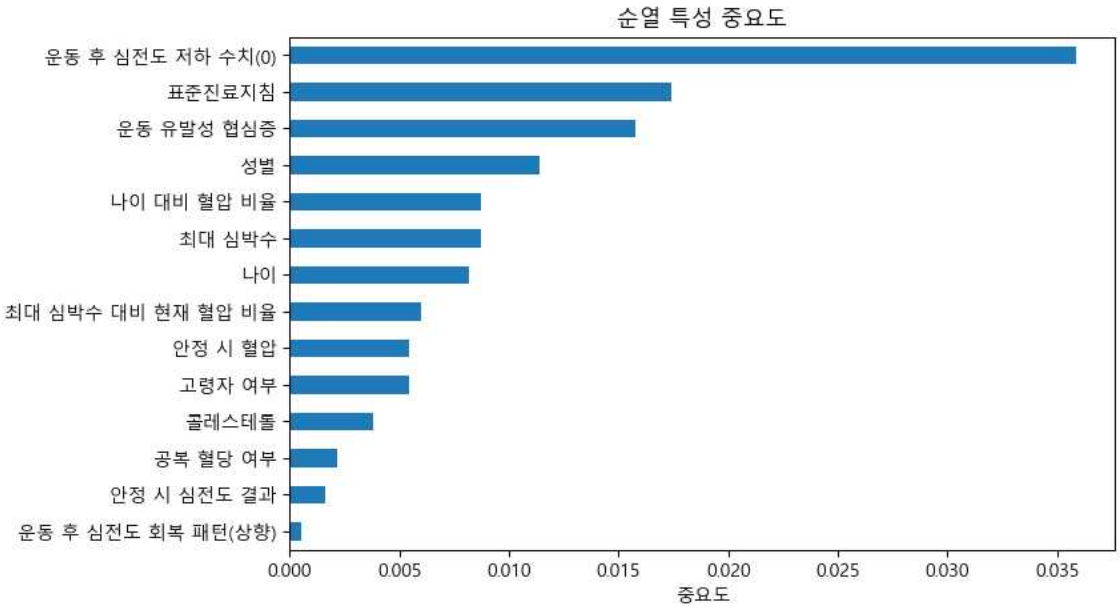

3.3 모델 학습 결과 및 다각적 성능 검증

○ 예측값과 실제값 분석 시각화

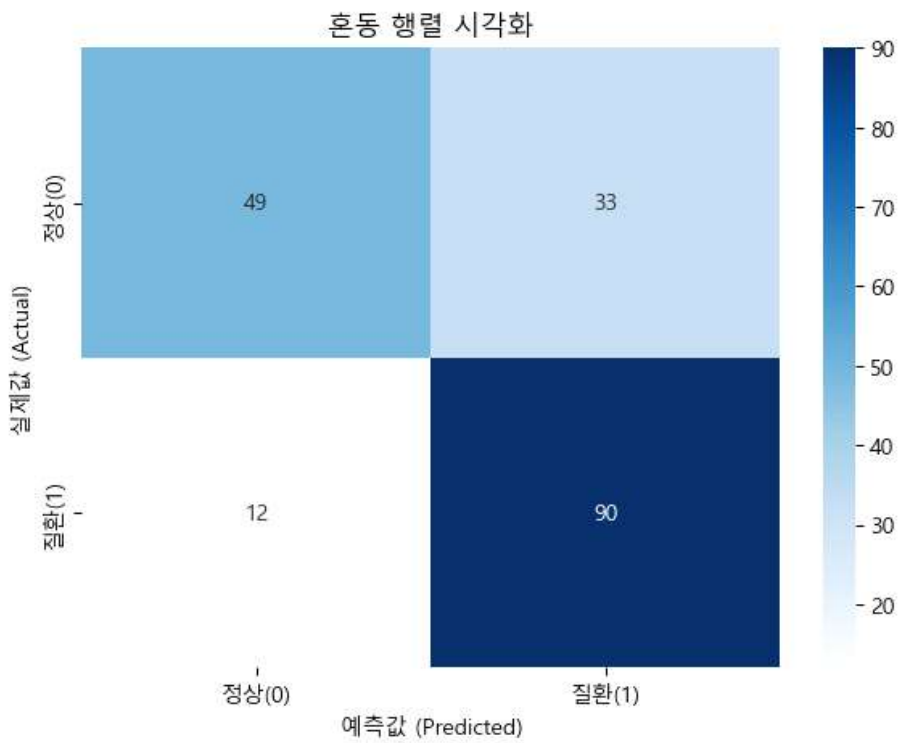

4. 프로토타이핑(화면)

4.1 모델 예측

○ 심장 질환 위험도 예측

- 나이 : 26, 성별 : 남, 표준진료지침 : 무증상
  안정시 심전도 결과 : 정상,
  운동 유발성 협심증 : False, 운동 후 심전도 저하 수치 : 1, 운동 후 심전도 회복 패턴 : 상향
  최대 심박수 : 180, 안정 시 혈압 : 72, 콜레스테롤 : 123, 공복 혈당 여부 : False

- 나이 : 33, 성별 : 남, 표준진료지침 : 무증상
  안정시 심전도 결과 : ST-T 이상,
  운동 유발성 협심증 : True, 운동 후 심전도 저하 수치 : 10, 운동 후 심전도 회복 패턴 : 하향
  최대 심박수 : 180, 안정 시 혈압 : 150, 콜레스테롤 : 200, 공복 혈당 여부 : True

5. 결론 및 한계점

○ 결론

- UCI 심장질환 데이터를 활용하여 4개 분류 모델을 비교한 결과, 로지스틱 회귀모델이 가장 우수한 성능을 보였고 하이퍼파리미터 최적화 및 ROC를 통해 모델의 분류 신뢰성을 검증하였으며, 운동 유발성 협심증, 표준진료지침, 운동 후 심전도 저하 수치가 심장질환 예측의 핵심 변수임을 확인

○ 한계점

- 연령이 낮은 경우 임상적으로 명확한 위험 지표가 있어도 모델이 과소평가하는 경향이 있으며, 이는 훈련 데이터 내 젊은 고위험군 사례 부족 때문에 발생하는 것으로 판단된다.
- 전체 데이터의 13.7%가 결측치로, 중앙값/최빈값 대체 방식의 한계로 인해 정보 손실이 발생